

Pattern Recognition Assignment



Who Is The Killer?

A Pattern Recognition and Machine Learning Investigation

Associate Professor: Dionisios N. Sotiropoulos

Ομάδα

**Αλέξιος Καστανάρας Π22062,
Δημήτριος Λαζανάς Π22082,
Δανάη Χαρζάκα Π22194**

Contact email for the group: alexioskast@gmail.com

Methodology Pipeline

- **Data Preprocessing:** Κανονικοποίηση & Κωδικοποίηση χαρακτηριστικών.
- **Exploratory Data Analysis (Q1-Q2):** Κατανομές, χωροχρονικά μοτίβα & MLE.
- **Generative Modeling (Q3):** Multiclass Gaussian Bayes.
- **Discriminative Classifiers (Q4-Q6):** Linear Models, SVM (RBF), και Multi-Layer Perceptron.
- **Latent Space Analysis (Q7-Q8):** Μείωση διαστάσεων με PCA και ομαδοποίηση με K-means.
- **Final Solution:** Aggregation μέσω Ensemble.

Data Preprocessing

Πριν την εκπαίδευση των μοντέλων, τα δεδομένα υπέστησαν αυστηρή προετοιμασία για την εξασφάλιση αριθμητικής σταθερότητας.

- **Continuous Features:** Εφαρμογή **Min-Max Scaling** (χαρτογράφηση στο διάστημα 0-1) και στην συνέχεια στρογγυλοποίηση στα 3 δεκαδικά ψηφία για μείωση του υπολογιστικού θορύβου.
- **Categorical Features:** Εφαρμογή **One-Hot Encoding** στα χαρακτηριστικά `weapon_code`, `scene_type` και `weather`.


Q1. Exploratory Distributions

Διερεύνηση των 1D κατανομών για την κατανόηση των βασικών μεταβλητών του συνόλου δεδομένων.

- **Τοποθεσία** (latitude, longitude): Οι κατανομές παρουσιάζουν συγκεντρώσεις με ελαφριά ασυμμετρία (Skewness: 0.13 και 0.22 αντίστοιχα).
- **Ηλικία Θύματος**: Έντονη αρνητική ασυμμετρία (-0.70), υποδεικνύοντας στοχευμένες ηλικιακές ομάδες πολύ νέα ή πολύ ηλικιωμένα θύματα.


latitude Distribution

Histogram with KDE overlay




victim_age Distribution

Histogram with KDE overlay



longitude Distribution


Histogram with KDE overlay



Q1. Temporal Patterns (hour_float)


Πότε "χτυπούν" οι δολοφόνοι;

- **Ανεπάρκεια Απλής Γκαουσιανής:** Η χρήση μιας απλής κατανομής απλοποιεί υπερβολικά τα δεδομένα και αποτυγχάνει να εντοπίσει την πολυτροπικότητα του συνόλου.
- **3-Component Gaussian Mixture Model (GMM):** Αναδεικνύει τρία ξεκάθαρα χρονικά "hotspots" εγκληματικότητας:
 - **Peak 1 (~12:00):** Κύρια μεσημεριανή δραστηριότητα.
 - **Peak 2 (~19:00):** Δραστηριότητα αργά το απόγευμα/βράδυ.
 - **Peak 3 (~06:00):** Σημαντική πρωινή δράση.



Q1. 2D Spatial-Temporal Structures

- Η 2D ανάλυση αποκαλύπτει μη τετριμμένα, διακριτά μοτίβα που ορίζουν εγκληματικές "περιοχές δράσης".
- **Εντοπίστηκαν 3 κύριες ζώνες δράσης:**
 1. Γεωγραφικό πλάτος (37.9, 38.1) / Ώρες: 00:00 - 15:00.
 2. Γεωγραφικό πλάτος (38.1, 38.2) / Ώρες: 09:00 - 20:00.
 3. Γεωγραφικό πλάτος (37.7, 38.0) / Ώρες: 10:00 - 23:59.





Q2. Maximum Likelihood Estimation (MLE)

- **Εκτίμηση Παραμέτρων:** Απομονώνοντας το TRAIN split, υπολογίσαμε τους εκτιμητές Μέγιστης Πιθανοφάνειας (MLE) για:
 - Το διάνυσμα μέσης τιμής $\hat{\mu}_k$
 - Τον πίνακα συνδιακύμανσης $\hat{\Sigma}_k$
- **Επαλήθευση:** Η υλοποίησή μας με numpy επαληθεύτηκε αριθμητικά ως προς τη λογαριθμική πιθανοφάνεια με την έτοιμη συνάρτηση της βιβλιοθήκης scipy.stats.

Q2. Feature Relationships per Killer

Αναλύοντας τις συσχετίσεις μεταξύ των μεταβλητών για κάθε killer.

- Πίνακες Συνδιακύμανσης & Συσχέτισης: Υπολογίσαμε τους πίνακες $\hat{\Sigma}_k$ και $\hat{R}_k$ για κάθε έναν από τους 8 δολοφόνους.




Q2. Mapping Territories


Διαχωρισμός μέσω αποστάσεων Mahalanobis.

- **Οριοθέτηση Περιοχών:** Προβάλαμε τα δεδομένα στο 2D επίπεδο **longitude vs latitude** και **hour_float vs latitude** και υπολογίσαμε τη μέγιστη απόσταση Mahalanobis για τα περιστατικά κάθε δολοφόνου.

Mahalanobis Ellipses: longitude vs latitude




Mahalanobis Ellipses: hour_float vs latitude



Q3. Multiclass Gaussian Bayes Classifier

- **Η Μεθοδολογία:** Κατασκευάσαμε έναν Generative ταξινομητή βασισμένο αποκλειστικά στα continuous features.
- **Πιθανότητες (Priors):** Η a priori πιθανότητα για κάθε δολοφόνο υπολογίστηκε βάσει της συχνότητας εμφάνισής του στο TRAIN set.
- **Κανόνας του Bayes:** Υπολογίσαμε την a posteriori πιθανότητα χρησιμοποιώντας τις κατανομές $\hat{\mu}_k$ και $\hat{\Sigma}_k$ από το Q2.
- **Απόδοση (Sanity & Generalization):**
 - TRAIN Accuracy: 90.14%.
 - VAL Accuracy: 90.61%.


Confusion matrix of Bayesian classification on VAL
Accuracy: 90.61%



Q3. Visualising Decision Regions (PCA Space)


Αποτυπώνοντας τα όρια απόφασης σε 2D.

- **Η Προσέγγιση:** Εφαρμόσαμε PCA για να προβάλουμε τα 8 συνεχή χαρακτηριστικά στις 2 πρώτες κύριες συνιστώσες (PC1, PC2).
- **Non-Linear Boundaries:** Τα όρια απόφασης του Bayes Classifier είναι εξαιρετικά μη-γραμμικά και προσαρμόζονται στον πίνακα συνδιακύμανσης $\hat{\Sigma}_k$ της κάθε κλάσης.




Q4. Discriminative Linear Classification

- **Πλήρης Χώρος Χαρακτηριστικών:** Σε αντίθεση με το Q3, εδώ χρησιμοποιήσαμε το πλήρες διάνυσμα χαρακτηριστικών $x_i \in \mathbb{R}^d$, ενσωματώνοντας και τα One-Hot Encoded κατηγορικά δεδομένα.
- **Το Μοντέλο:** Χρησιμοποιήθηκε SGDClassifier με logistic loss, ρυθμισμένο σε διάταξη One-Vs-Rest για την πολυταξική ταξινόμηση.
- **Απόδοση:** Μετά από hyperparameter tuning για το L2 regularization, η ακρίβεια στο VAL split έφτασε το **92.17%**, ξεπερνώντας το Gaussian Bayes (90.61%).



Q4. Visualising Linear vs Non-Linear Boundaries


- **Οπτική Σύγκριση:** Προβάλαμε τα προσεγγιστικά γραμμικά όρια απόφασης πάνω στις μη-γραμμικές περιοχές του Bayes στον 2D PCA χώρο.
- Το γραμμικό μοντέλο δημιουργεί αυστηρά υπερέπιεδα και αδυνατεί να σχηματίσει τις προσαρμοστικές, ελλειπτικές καμπύλες του Q3.



Q5. Non-Linear Classification with SVMs


Αντιμετωπίζοντας την πολυπλοκότητα με μη-γραμμικά όρια.

- **Η Μεθοδολογία:** Χρήση Support Vector Machines με διάταξη One-vs-Rest στο πλήρες διάνυσμα χαρακτηριστικών.
- **Προαπαιτούμενο:** Εφαρμογή StandardScaler στα δεδομένα, καθώς τα SVMs είναι εξαιρετικά ευαίσθητα στην κλίμακα των χαρακτηριστικών.
- **Hyperparameter Tuning:** Μέσω GridSearchCV ελέγχοντας Polynomial και RBF kernels, καταλήξαμε στις βέλτιστες παραμέτρους: **Kernel = RBF, C = 10, gamma = 'scale'**.
- **Απόδοση (VAL Accuracy):** **91.86%** Καλύτερο από το Gaussian Bayes (90.61%), αλλά οριακά πιο κάτω από το Linear Model (92.17%).



Q5. Decision Regions & Support Vectors


- **Ευελιξία Ορίων:** Το RBF kernel δημιουργεί εξαιρετικά ευέλικτα, μη-γραμμικά όρια που "αγκαλιάζουν" τις συστάδες των δεδομένων (σε αντίθεση με τις ευθείες του Q4).
- Το γεγονός ότι το μοντέλο χρειάζεται τόσα πολλά διανύσματα υποστήριξης αποδεικνύει ότι οι κλάσεις αλληλεπικαλύπτονται σε τεράστιο βαθμό. Δεν υπάρχουν ξεκάθαρα, "καθαρά" περιθώρια μεταξύ των δολοφόνων στον 2D χώρο.




Q6. Multi-Layer Perceptron

- **Σχεδιασμός Εισόδου:** Διανύσματα 24 διαστάσεων που ενσωματώνουν τόσο συνεχή όσο και κατηγορικά χαρακτηριστικά.
- **Δομή Κρυφών Επιπέδων:** Τρία επίπεδα με 64, 32 και 8 νευρώνες αντίστοιχα, χρησιμοποιώντας τη συνάρτηση ενεργοποίησης ReLU.
- **Αποτροπή Overfitting:** Χρήση επιπέδου Dropout με ρυθμό 0.3 μετά το πρώτο κρυφό επίπεδο.
- **Επίπεδο Εξόδου:** 8 νευρώνες με συνάρτηση Softmax για την παραγωγή των τελικών πιθανοτήτων για τον κάθε δολοφόνο.
- **Στρατηγική Εκπαίδευσης:** Αλγόριθμος βελτιστοποίησης Adam με Categorical cross-entropy. Εφαρμογή Early Stopping (150 epochs) και δυναμική μείωση του learning rate (ReduceLROnPlateau).
- **Κορυφαία Απόδοση:** Το μοντέλο πέτυχε εξαιρετική ακρίβεια και Weighted F1-score που αγγίζουν το 95.0% στο σύνολο αξιολόγησης.

Confusion matrix for Neural Network
Weighted F1 score: 0.950




Q6. Decoding the "Black Box" (Feature Importance)



- **Μέθοδος:** Αξιολόγηση μέσω Permutation Feature Importance στο σύνολο επαλήθευσης (VAL).
- **Κρίσιμο Εύρημα:** Η ηλικία του θύματος αποτελεί μακράν το πιο καθοριστικό χαρακτηριστικό. Η αλλοίωσή του προκαλεί τεράστια πτώση στην ακρίβεια (~25%), υποδηλώνοντας ότι οι serial killers στοχεύουν πολύ συγκεκριμένες ηλικιακές ομάδες.
- **Δευτερεύοντα Χαρακτηριστικά:** Η χωρική εγγύτητα από αστυνομικά τμήματα (dist_precinct_km) και τα στοιχεία της σκηνής (weather, scene_type, weapon_code) προσφέρουν επίσης ουσιαστική διακριτική ικανότητα στο νευρωνικό δίκτυο.


Q7. Dimensionality Reduction with PCA

- **Προσέγγιση & Επιλογή Μοντέλου:** Κανονικοποίηση των συνεχών χαρακτηριστικών και χρήση των one-hot encoded κατηγορικών μεταβλητών. Εφαρμογή PCA αποκλειστικά στο σύνολο TRAIN για τη δημιουργία ενός "modus operandi" χώρου χαμηλότερων διαστάσεων.
- **Πειραματικά Αποτελέσματα:** Επιλέχθηκαν $m=16$ κύριες συνιστώσες, καθώς επαρκούν για να εξηγήσουν το 95% της συνολικής διασποράς των δεδομένων.




Q7. PCA 2D Projection

- **2D Projection:** Προβάλλοντας το VAL split στις 2 πρώτες συνιστώσες PC1 & PC2 και χρωματίζοντας με βάση τις προβλέψεις του SVM, παρατηρούμε έντονη επικάλυψη στο κέντρο του χώρου. Αυτό επιβεβαιώνει ότι οι 2 διαστάσεις δεν αρκούν για τον διαχωρισμό των δραστών και εξηγεί τη δυσκολία των απλών γραμμικών μοντέλων.



Q8. Unsupervised Clustering in Latent Space

- **Προσέγγιση & Επιλογή Μοντέλου:** Μετάβαση unsupervised μάθηση. Τα δεδομένα προβλήθηκαν στον latent space των 16 διαστάσεων. Εφαρμογή του αλγορίθμου K-means με $k=8$ πάνω στο TRAIN split. Η αντιστοίχιση των clusters στις τελικές ετικέτες έγινε μέσω πλειοψηφικής ψηφοφορίας.
- **Πειραματικά Αποτελέσματα:** Το K-means πέτυχε ικανοποιητική ακρίβεια $\sim 83.9\%$ σε VAL και TEST splits. Ωστόσο, το χαμηλό silhouette score (0.155) επιβεβαιώνει ποσοτικά την υψηλή αλληλεπικάλυψη των προφίλ.
- **Οπτικά Συμπεράσματα:** Το γράφημα δείχνει πώς το K-means χωρίζει αυστηρά τον χώρο σε γεωμετρικές περιοχές. Επίσης, η πλειοψηφική ψηφοφορία ανέδειξε σημαντική ανισορροπία, με τον "Killer 3" (πράσινο) να "απορροφά" τα περισσότερα clusters λόγω της υψηλής πυκνότητας δεδομένων στη συγκεκριμένη περιοχή.



Final Submission

Προσέγγιση & Μεθοδολογία:

- Για τη δημιουργία του τελικού αρχείου **submission.csv**, επιλέχθηκε η στρατηγική του Soft Voting Ensemble.
- Συνδυάστηκαν οι πιθανότητες από τα τρία πιο ισχυρά διακριτικά μοντέλα μας: το Linear Classifier, το SVM και το MLP.
- Ο υπολογισμός έγινε παίρνοντας τον απλό μέσο όρο των πιθανοτήτων:

$$\hat{\pi}_i^{(ensemble)}(k) = \frac{1}{3} \sum_{m=1}^3 \hat{\pi}_i^{(m)}(k)$$

- Η τελική σκληρή ταξινόμηση για το ποιος είναι ο δολοφόνος προκύπτει επιλέγοντας την κατηγορία με την υψηλότερη μέση πιθανότητα.
- Το τελικό παραγόμενο αρχείο δομήθηκε ώστε να περιλαμβάνει το incident_id, την τελική πρόβλεψη (predicted_killer) και τις 8 αντίστοιχες στήλες πιθανοτήτων (p_killer_1 έως p_killer_8).

Submission Confusion Matrix

- Αποτελέσματα:** Το μοντέλο αξιολογήθηκε απέναντι στα συνδυασμένα σύνολα VAL και TEST. Το ensemble πέτυχε εξαιρετική συνολική ακρίβεια **95.19%** και σταθμισμένο F1-score **94.97%**. Η επίδοση αυτή ξεπερνά πρακτικά το καλύτερο μεμονωμένο μοντέλο μας, το MLP.

